LLM 评测基准与各大排行榜单

01. LLM 评测基准

在前面的课时中，我们有粗略谈了下 LLM 是如何进行测评的，其实和人类考试、手机跑分、电脑跑分一样，也是先预定一定的基准（测试题），然后让 LLM 回复并且使用人工/AI/半自动进行打分，最后得到一个多模型的排行榜信息。

所以对于 LLM 评测来说，选择什么样的试题基准非常重要，试题是否公开（在巨大利益的驱使下，数据在公开的情况下，刷榜的可能性会大大增加，不公开又不够公平）、评测次数、打分方式都会影响到 LLM 的评测结果。

相比传统的 NLP，使用以往的任务评测（做什么任务就在对应的数据集上评测）已经逐渐不足以综合评估一个模型，针对 LLM 评测的数据集一般都会包含多个方向，例如包含数学、历史、计算机科学、法律，将多个方向的试题组成一个评测基准，如果一个通用大语言模型想要效果好，需要同时具备世界知识（world knowledge），以及解题能力（problem solving）。

基于这个指标，也涌现出了不少中文评测基准：

- AGIEval：选中标准化考试提问，中英文共计 8062 道题目，题目来源于高考题、公务员考试、律师资格证等。
- C-EVal：共计接近 14000 个问题，包含 52 个不同领域，4 大类：STEM(科学/技术/工程/数学)、社会科学、人文、其他。
- XIEZHI：涵盖了来自 516 个领域的总共 249587 道多选题，可以用来测试模型在不同领域上的优势和劣势。
- CMMLU：涵盖 11528 个多选题，横跨 67 个科目，涉及一些不是常见标准化考试类型的题目，例如食物，中国驾驶规范等。

了解了用什么做测试，接下来就是如何测试，其实也就是如何打分，一般来说分为 3 类：**自动评测**(选择题等有固定答案的场景)、**人工评测**、**GPT-4评测**(使用一个性能公认最强大的模型来进行打分，而且越来越多的模型使用这种方式来打分)。

其实经过前面的学习与 LLMOps 的开发，LLM 的输出具有随机性，并且因为 ReRank 的存在，简单地把不同答案顺序做调换喂给模型，也会影响到最终结果，所以使用一个强性能的 LLM 进行评测也是存在误差的，所以 `评测数据集` 和 `评测方法` 永远都只能作为参考，没法 100% 反映 LLM 的能力。

回到现实，即使各家公司都在积极发展自己的模型，评测这一部分恐怕都被严重忽视，或者沦为 PR 的一种工具，毕竟 LLM 的诞生目标也不是为了成功解决各种人类考题，而是因为达到了一定的知识与推理水平，所以可以成功解决人类考题。

02. LLMs 评测榜单

目前市面上可选择 LLM 非常多，除了 OpenAI 官方的 GPT 系列，还有 Gemini、Claude、Kimi、Deepseek、Gork、通义千问、文心一言等众多服务提供商，并且每个服务提供商配置的模型也五花八门，如何挑选一个适合当前企业业务的 LLM 呢?

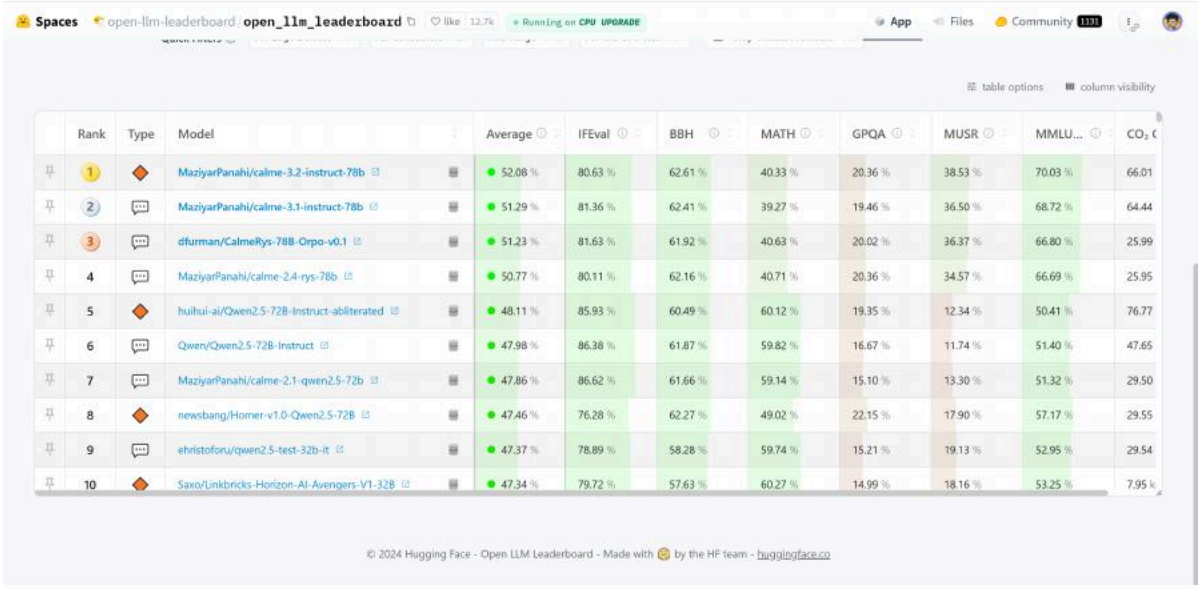
自行测试不仅费时费力，而且消耗成本巨大，一些评测基准甚至有几万道题，逐个测试成本会庞大到难以接受，这时候可以考虑一些相对 “公平” 的 LLMs 评测榜单，在课程中我也整理了一些目前还比较活跃的 LLMs 评测榜单，大家在选择 LLM 的时候也可以作为一个参考。

2.1 Open LLM Leaderboard

Open LLM Leaderboard 是 Huggingface 官方发布的一个主要针对英文的 LLMs 评测榜单，旨在于跟踪、排名和评估开源的 LLMs，榜单有 4 个基准：

- AI2 Reasoning Challenge (25-shot)：主要涵盖了一些小学科学问题。
- HellaSwag (10-shot)：常识推理数据集，～95%的问题对人类来说很容易，但对语言模型来说非常具有挑战性。
- MMLU (5-shot)：一个常用于衡量模型在多任务准确性的 benchmark，主要涵盖了基础数学、美国历史、计算机科学、法律等57项任务。
- TruthfulQA (0-shot)：一个用于测试模型谎言倾向的 benchmark。

榜单地址：https://huggingface.co/spaces/open-llm-leaderboard/open_llm_leaderboard



2.2 Chatbot Arena

这是 LMSYS 推出的一个以众包方式进行匿名、随机匹配的 LLMs 基准平台，主要包括以下测试基准：

- Chatbot Arena：一个大语言模型基准平台，目前已有 90K+ 用户的投票数据，采用 Elo 评级方法进行计算得到的结果。
- MT-Bench：一个多轮问题对话 benchmark，并且使用 GPT-4 的结果作为标准进行评分。
- MMLU (5-shot)：一个常用于衡量模型在多任务准确性的 benchmark，主要涵盖了基础数学、美国历史、计算机科学、法律等57项任务。

榜单地址：https://huggingface.co/spaces/lmarena-ai/chatbot-arena-leaderboard

Total #models: 212. Total #votes: 2,768,389. Last updated: 2025-03-10.

Code to recreate leaderboard tables and plots in this notebook. You can contribute your vote at lmarena.ai!

Category: Overall

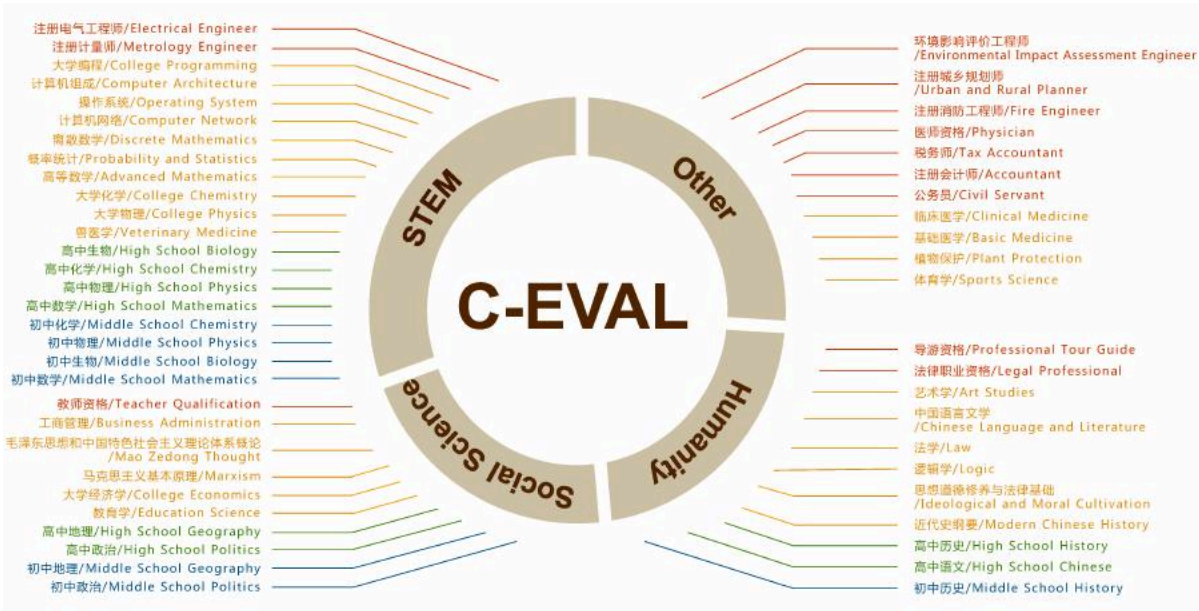
Apply filter: Style Control, Show Deprecated

Overall Questions: #models: 212 (100%) #votes: 2,768,389 (100%)

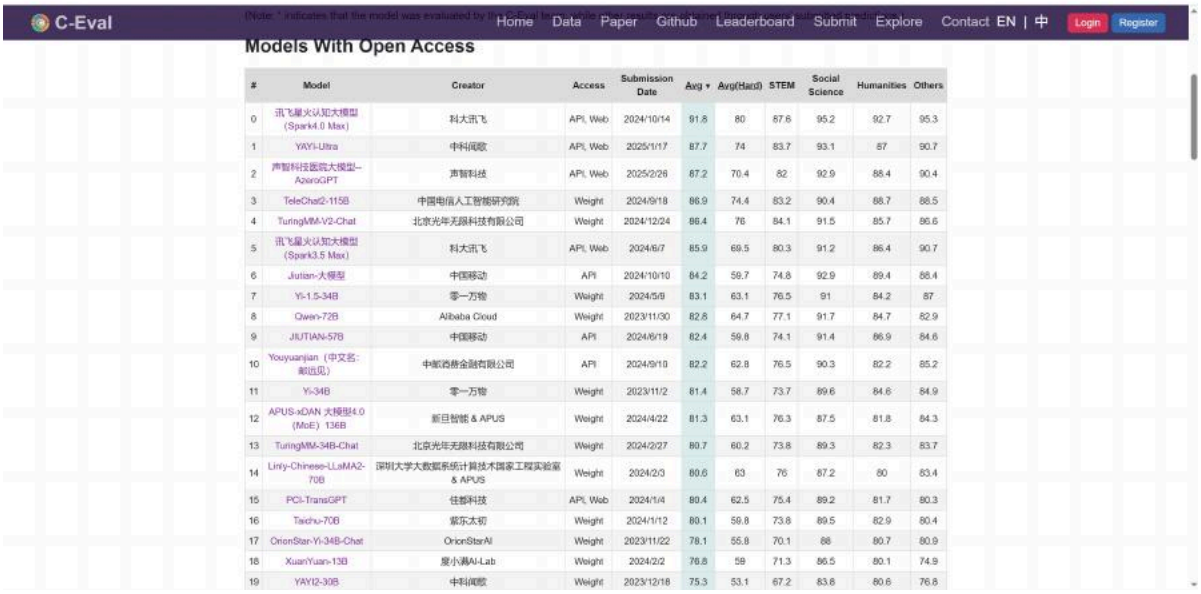
Rank* (UB)	Rank (StyleCtrl)	Model	Arena Score	95% CI	Votes	Organization	License	Knowledge Cutoff
1	2	Grok-3-Preview-02-24	1407	+7/-7	7580	xAI	Proprietary	Unknown
1	1	GPT-4.5-Preview	1404	+7/-9	6024	OpenAI	Proprietary	Unknown
1	2	chocolate (Early Grok-3)	1402	+5/-5	14006	xAI	Proprietary	Unknown
4	7	Gemini-2.0-Flash-Thinking-Exp-01-21	1384	+5/-5	19837	Google	Proprietary	Unknown
4	3	Gemini-2.0-Pro-Exp-02-05	1380	+4/-4	17695	Google	Proprietary	Unknown
4	2	ChatGPT-4o-latest (2025-01-29)	1375	+4/-5	19587	OpenAI	Proprietary	Unknown
7	5	DeepSeek-R1	1361	+5/-6	10474	DeepSeek	MIT	Unknown
7	11	Gemini-2.0-Flash-001	1355	+4/-5	15416	Google	Proprietary	Unknown
7	3	o1-2024-12-17	1353	+4/-4	22010	OpenAI	Proprietary	Unknown
10	11	Gemma-3-27B-it	1339	+9/-11	3870	Google	Gemma	Unknown
10	11	Qwen2.5-Max	1338	+5/-5	14258	Alibaba	Proprietary	Unknown

2.3 C-Eval

C-Eval 是清华大学、上海交通大学和爱丁堡大学联合发布的一个 LLMs 中文模型评估套件，整个评测基准包含了接近 14000 个多项选择题，涵盖了 52+ 个学科和四个难度。



相比其他榜单，这份榜单内更多的是国内的模型参与评测（但是更新速度并不是很快），可作为参考：



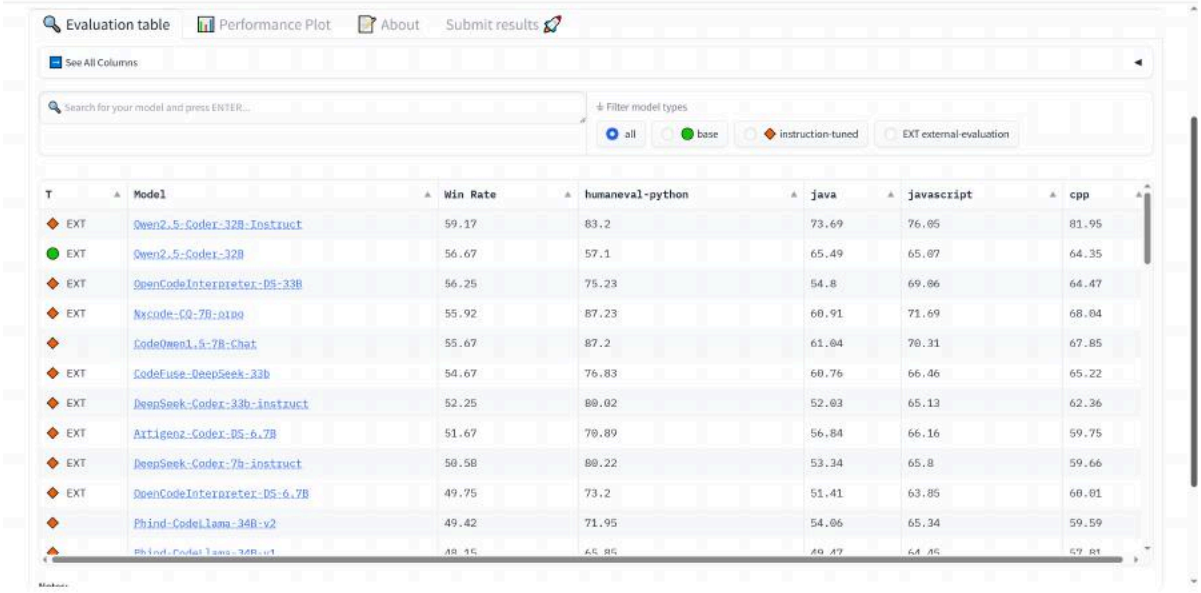
#	Model	Creator	Access	Submission Date	Avg	Avg(Hard)	STEM	Social Science	Humanities	Others
0	讯飞星火认知大模型 (Spark4.0 Max)	科大讯飞	API, Web	2024/10/14	91.8	80	87.6	95.2	92.7	95.3
1	YAYI-Ultra	中科闻歌	API, Web	2025/1/17	87.7	74	83.7	93.1	87	90.7
2	声智科技医院大模型--AzeroGPT	声智科技	API, Web	2025/2/26	87.2	70.4	82	92.9	88.4	90.4
3	TeleChat2-115B	中国电信人工智能研究院	Weight	2024/9/18	86.9	74.4	83.2	90.4	88.7	88.5
4	TuringMM-V2-Chat	北京光年无限科技有限公司	Weight	2024/12/24	86.4	76	84.1	91.5	85.7	86.6
5	讯飞星火认知大模型 (Spark3.5 Max)	科大讯飞	API, Web	2024/6/7	85.9	69.5	80.3	91.2	86.4	90.7
6	Jiutian-大模型	中国移动	API	2024/10/10	84.2	59.7	74.8	92.9	89.4	88.4
7	Yi-1.5-34B	零一万物	Weight	2024/5/9	83.1	63.1	76.5	91	84.2	87
8	Qwen-72B	Alibaba Cloud	Weight	2023/11/30	82.8	64.7	77.1	91.7	84.7	82.9
9	JIUTIAN-57B	中国移动	API	2024/6/19	82.4	59.8	74.1	91.4	86.9	84.6
10	Youyuanjian（中文名：昴远见）	中邮消费金融有限公司	API	2024/9/10	82.2	62.8	76.5	90.3	82.2	85.2
11	Yi-34B	零一万物	Weight	2023/11/2	81.4	58.7	73.7	89.6	84.6	84.9
12	APUS-xDAN 大模型4.0 (MoE) 136B	新旦智能 & APUS	Weight	2024/4/22	81.3	63.1	76.3	87.5	81.8	84.3
13	TuringMM-34B-Chat	北京光年无限科技有限公司	Weight	2024/2/27	80.7	60.2	73.8	89.3	82.3	83.7
14	Linly-Chinese-LLaMA2-70B	深圳大学大数据系统计算技术国家工程实验室 & APUS	Weight	2024/2/3	80.6	60	76	87.2	80	83.4
15	PCI-TransGPT	佳都科技	API, Web	2024/1/4	80.4	62.5	75.4	89.2	81.7	80.3
16	Taichu-70B	紫东太初	Weight	2024/1/12	80.1	59.8	73.8	89.5	82.9	80.4
17	OrionStar-Yi-34B-Chat	OrionStarAI	Weight	2023/11/22	78.1	55.8	70.1	88	80.7	80.9
18	XuanYuan-13B	度小满AI-Lab	Weight	2024/2/2	76.8	59	71.3	86.5	80.1	74.9
19	YAYI2-30B	中科闻歌	Weight	2023/12/18	75.3	53.1	67.2	83.8	80.6	76.8

榜单地址：https://cevalbenchmark.com/static/leaderboard.html

2.4 BigCode

BigCode 是一个在 HumanEval 和 MultiPL-E 两个基准上对多语言代码生成能力进行评估的榜单，并且还对模型的吞吐量进行了对比。主要包括了以下评测基准：

- HumanEval：一个用于评估从文档字符串合成程序的功能正确性的 benchmark，由 164 个 Python 编程问题组成。
- MultiPL-E：将 HumanEval 翻译成 18 种编程语言得到的数据集。



T	Model	Win Rate	humaneval-python	java	javascript	cpp
EXT	Qwen2.5-Coder-32B-Instruct	59.17	83.2	73.69	76.05	81.95
EXT	Qwen2.5-Coder-32B	56.67	57.1	65.49	65.07	64.35
EXT	OpenCodeInterpreter-DS-33B	56.25	75.23	54.8	69.06	64.47
EXT	Nxcode-CQ-7B-orpo	55.92	87.23	60.91	71.69	68.04
	CodeQwen1.5-7B-Chat	55.67	87.2	61.04	70.31	67.85
EXT	CodeFuse-DeepSeek-33b	54.67	76.83	60.76	66.46	65.22
EXT	DeepSeek-Coder-33b-instruct	52.25	80.02	52.03	65.13	62.36
EXT	Artigenz-Coder-DS-6.7B	51.67	70.89	56.84	66.16	59.75
EXT	DeepSeek-Coder-7b-instruct	50.58	80.22	53.34	65.8	59.66
EXT	OpenCodeInterpreter-DS-6.7B	49.75	73.2	51.41	63.85	60.01
	Phind-CodeLlama-34B-v2	49.42	71.95	54.06	65.34	59.59
	Phind-CodeLlama-34B-v1	48.15	65.85	49.47	64.46	57.81

榜单地址：https://huggingface.co/spaces/bigcode/bigcode-models-leaderboard